2026

제 3의 손

VLA Motion Control via Voice Interface

음성명령 기반 VLA(Vision-Language-Action) 로봇 동작제어 시스템 구현

https://github.com/jeong-bin-98/Dobot_VLM_VLA

INDEX

01 팀 소개 및 진행 일정

02 프로젝트 시나리오

03 추진 배경 및 필요성

04 시스템 구현 및 핵심 기술

05 트러블슈팅 및 성능 평가

06 아쉬운 점 및 향후 발전 방향

VLA Motion Control via Voice Interface

INDEX

01 팀 소개 및 진행 일정

02 프로젝트 시나리오

03 추진 배경 및 필요성

04 시스템 구현 및 핵심 기술

05 트러블슈팅 및 성능 평가

06 아쉬운 점 및 향후 발전 방향

VLA Motion Control via Voice Interface

팀 소개 및 진행일정



홍정빈
기획·PM / 하드웨어



양현우
하드웨어 / 데이터 수집



김재근
데이터 수집 / 하드웨어



정성재
기획·PM / 음성 모듈



윤영진
데이터 수집 / 음성 모듈

Phase / Role	Task Description	Day 1~2	Day 3~5	Day 6~8	Day 9~11	Day 12
기획 및 PM	프로젝트 기획	PLANNING				
	발표자료 제작 및 시연					DEMO
하드웨어	하드웨어 선정	SELECT				
	하드웨어 세팅		SETUP			
데이터 수집 및 학습	학습용 데이터 수집		DATA COLLECTION			
	VLA 모델별 학습		MODEL TRAINING			
음성 모듈	음성 모듈 개발		DEV			
	음성 모듈 통합				INTEGRATION	

INDEX

01 팀 소개 및 진행 일정

02 프로젝트 시나리오

03 추진 배경 및 필요성

04 시스템 구현 및 핵심 기술

05 트러블슈팅 및 성능 평가

06 아쉬운 점 및 향후 발전 방향

INNOVATING YOUR FUTURE


x8



INDEX

01 팀 소개 및 진행 일정

02 프로젝트 시나리오

03 추진 배경 및 필요성

04 시스템 구현 및 핵심 기술

05 트러블슈팅 및 성능 평가

06 아쉬운 점 및 향후 발전 방향

INNOVATING YOUR FUTURE

VLA 에이전트의 부상: 생각을 넘어 물리적 행동으로

단순히 텍스트를 생성하는 AI에서, 세상을 보고 직접 행동하는 로봇의 뇌로 진화



텍스트 기반 언어 모델

질문에 텍스트로만 답하는
1세대 AI 에이전트

시각 + 언어 통합 모델

이미지를 보고 설명하지만
행동은 하지 못하는 단계

시각 + 언어 + 행동 통합

세상을 보고 이해하며
물리적 행동까지 생성하는 AI

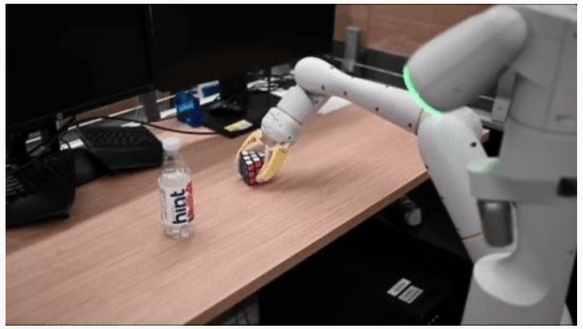
Physical AI

정답을 말하는 AI에서, 움직이는 AI로

AI는 이제 스크린을 넘어 물리적 세계로 걸어나오고 있습니다



[$\boldsymbol{\pi 0.5}$ VLA model]



[Google-deepmind RT-2 Robot]



[Tesla Optimus]



[LG CLOiD]



[NVIDIA Alphamayo]

기획 의도: 제3의 손이 있다면?

Physical AI를 일상의 소소한 재미와 편리함으로 연결하다



[캐임브리지 university]



[지자이 로봇]

손이 하나 더 있다면?



일상 속 귀찮은 순간들

게임 중 물 한 모금, 코딩 중 간식 한 입

그 3초가 흐름을 끊는 그 귀찮음.

결론: 내 책상 위 AI 로봇 비서, "제3의 손" 탄생

INDEX

01 팀 소개 및 진행 일정

02 프로젝트 시나리오

03 추진 배경 및 필요성

04 시스템 구현 및 핵심 기술

05 트러블슈팅 및 성능 평가

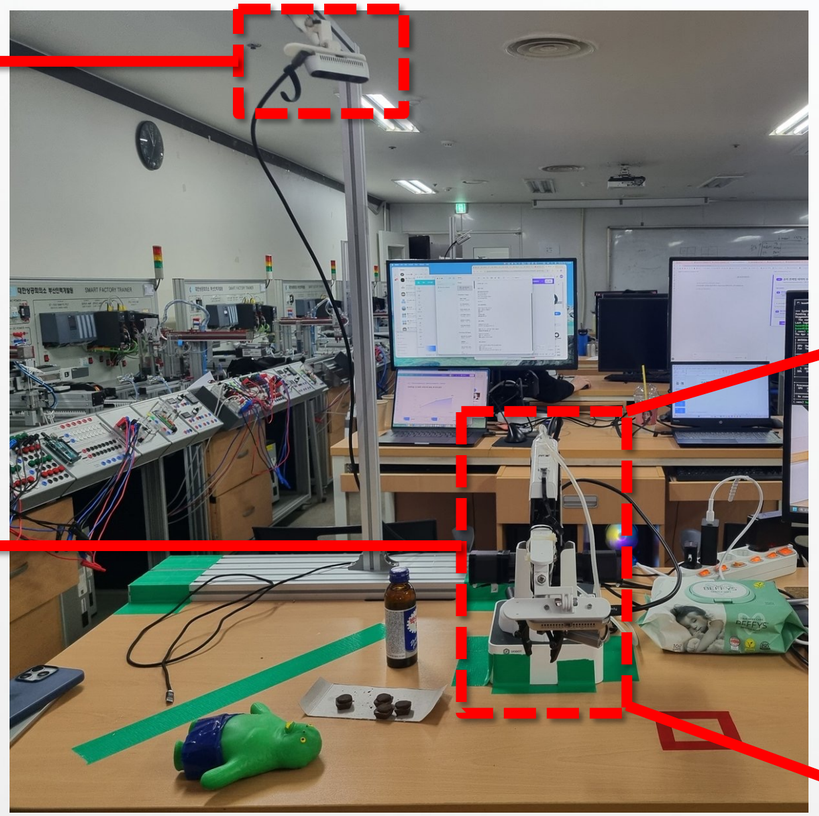
06 아쉬운 점 및 향후 발전 방향

System Setup

Setup 사진

Top Camera

Dobot Magician



Wrist Camera



실험 물품



System Architecture

Speech-to-Instruction → VLA Inference → Execution 추론 파이프라인의 전체 흐름

a) Speech-to-Instruction

a-1. Language Input



"나 너무 배고파"

Audio, A

A

a-2. Qwen2.5-ASR

Audio, A → "나 너무 배고파"

Text, T

T

a-3. Qwen-3.0

"나 너무 배고파" (Text, T)

pick up the snack (language instruction)

System Prompt

Language Instruction

b) VLA Inference

b-1. Cameras



Wirst Camera



Top Camera

b-2. LeRobot

LeRobot

$\pi 0$ VLA Policy

Robot State

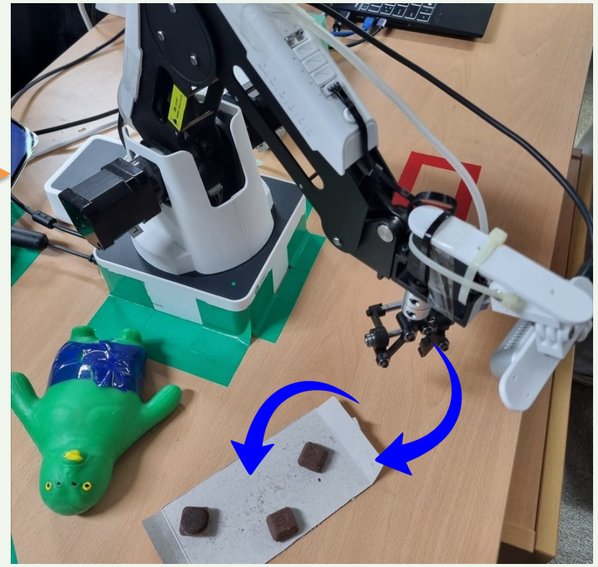
$[x, y, z, r, grip]$

Action Chunk

$[\Delta x, \Delta y, \Delta z, \Delta r, grip]$

C) Execution

c-1. Dobot Magician





t = 0



t = 1



t = 2

핵심기술

Data Collection → Speech → VLA → Execution 파이프라인 설계

01



순차 프레임 데이터 수집

- 리더 / 팔로워 (Teleoperation) 없이 프레임 단위 데이터 수집

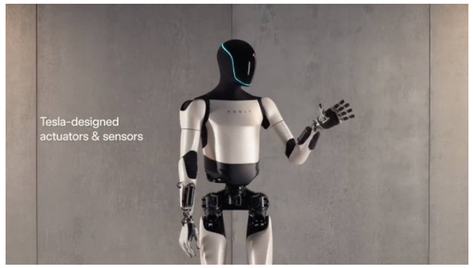
02



의도 파싱 LLM Chaining

- Qwen2.5-ASR로 음성을 텍스로 변환
- Qwen3.0으로 시스템 프롬프트 기반 작업 명령 매핑

03



VLA 행동 정책

- $\pi 0$ VLA 모델을 파인튜닝
- 듀얼 카메라, 로봇상태, 언어명령을 통합 처리

04



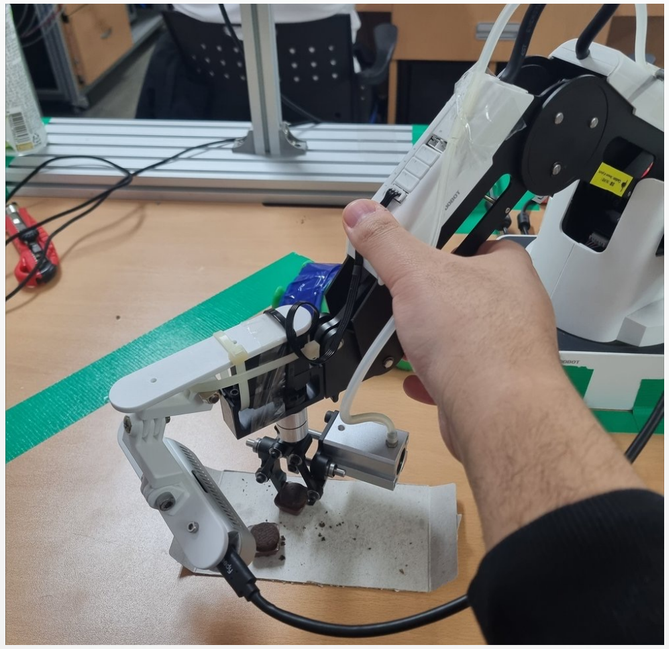
Δ Action 표현

- Cartesian 변위값 출력
- 관절 역기구학은 Dobot 펌웨어 활용

순차 프레임 데이터 수집

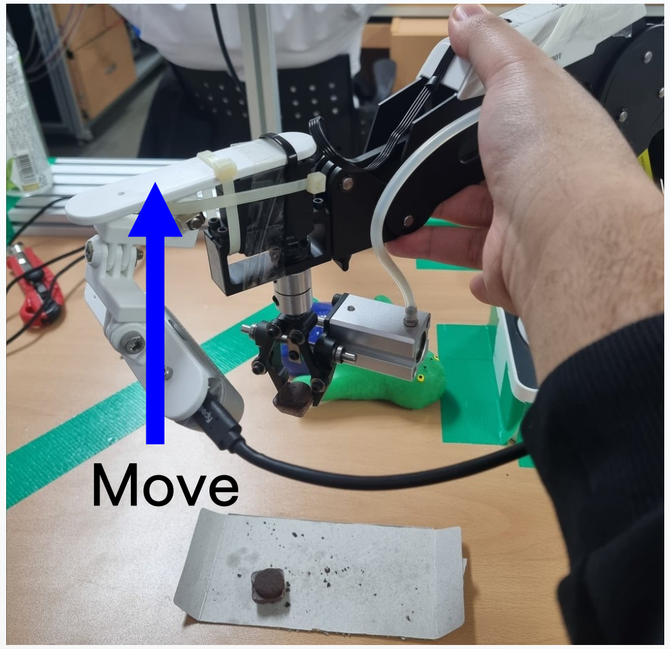
Single-Arm Sequential Teleoperation – 리더 / 팔로워 없는 프레임 단위 데이터 구축

관측 캡처



- 듀얼 카메라 (Top + Wrist) 이미지 촬영
- **로봇 상태 $[x, y, z, r, grip]$ 기록**

변위 값 기록



- 듀얼 카메라 (Top + Wrist) 이미지 촬영
- **변위 값 $[\Delta x, \Delta y, \Delta z, \Delta r, grip]$ 기록**

의도 파싱 LLM Chaining

음성 명령 분류

Qwen 3.0 LLM이 발화를 분석해 로봇 명령을 생성합니다.

음성 입력 (STT, Qwen2.5-ASR – 7B)	키워드 (LLM, Qwen3.0 – 8B)	$\pi 0$ 프롬프트
“배고프다”	과자	pick up the snack
“목 마르다“	음료	pick up the beverage
“흑, 흑, 너무 슬퍼"	휴지	pick up the tissue
“아 진짜 우리팀 뭐해”	스트레스	pick up the stresstoy

- snack

```
▶ 1단계: STT (Qwen2.5-ASR)
  입력: 마이크 음성
  출력: "아 배고픈데?"

▶ 2단계: Qwen3.0 의도 분류
  입력: "아 배고픈데?"
  출력: {
    type:           "dialog"
    command:        null
    response:       "배고프시군요."
    suggest_object: "과자"
  }

→ 대화 응답: 배고프시군요.
→ 바로 실행: pick up the snack
```

- beverage

```
▶ 1단계: STT (Qwen2.5-ASR)
  입력: 마이크 음성
  출력: "목마르다"

▶ 2단계: Qwen3.0 의도 분류
  입력: "목마르다"
  출력: {
    type:           "dialog"
    command:        null
    response:       "목이 마르시는군요."
    suggest_object: "음료"
  }

→ 대화 응답: 목이 마르시는군요.
→ 바로 실행: pick up the drink
```

- tissue

```
▶ 1단계: STT (Qwen2.5-ASR)
  입력: 마이크 음성
  출력: "흑흑, 너무 슬퍼빵"

▶ 2단계: Qwen3.0 의도 분류
  입력: "흑흑, 너무 슬퍼빵"
  출력: {
    type:           "dialog"
    command:        null
    response:       "많이 슬프시군요. 괜찮아질 거예요."
    suggest_object: "휴지"
  }

→ 대화 응답: 많이 슬프시군요. 괜찮아질 거예요.
→ 바로 실행: pick up the tissue
```

- stress

```
▶ 1단계: STT (Qwen2.5-ASR)
  입력: 마이크 음성
  출력: "우리팀 뭐해?"

▶ 2단계: Qwen3.0 의도 분류
  입력: "우리팀 뭐해?"
  출력: {
    type:           "dialog"
    command:        null
    response:       "팀 상황이 궁금하시군요."
    suggest_object: "스트레스볼"
  }

→ 대화 응답: 팀 상황이 궁금하시군요.
→ 바로 실행: pick up the stresstoy
```

VLA 행동 정책

$\pi 0$ Vision-Language-Action(VLA) Policy → 사전학습 모델을 자체 데이터로 파인튜닝하여 행동 생성



SPEC **학습설정**

- **기반 모델** : lerobot/pi0_base (사전학습 가중치)
- **생성방식** : Flow Matching (연속 액션 직접 생성)
- **학습 GPU** : A6000 (48GB VRAM)
- **학습량** : 20,000 steps, batch = 4

Δ Action 표현

Cartesian 변위값을 출력하고 역기구학은 DOBOT 펌웨어에 위임

▪ Cartesian + 변위 값을 쓰는 이유

01

Cartesian

- Dobot 펌웨어가 move_to(x, y, z, r) 제공
  → 관절 기구학 학습 불필요

02

변위 값

- 현재 포즈 기준 상대 이동
  → 물체 위치가 달라져도 동일한 행동 패턴 적용

모델 출력 형태

$$[\Delta x, \Delta y, \Delta z, \Delta r, grip]$$

Cartesian 변위 값 + 그리퍼 상태

▪ 역기구학 계산

A) $\pi 0$ VLA 출력

$$\Delta = [+2.1\ , -0.5, +1.0, 0.0, 0.0]$$

B) Dobot : 절대 좌표 변환

```
cur = self.get_pose()

        tx = float(np.clip(cur[0] + delta[0], *BOUNDS["x"]))
        ty = float(np.clip(cur[1] + delta[1], *BOUNDS["y"]))
        tz = float(np.clip(cur[2] + delta[2], *BOUNDS["z"]))
        tr = float(np.clip(cur[3] + delta[3], *BOUNDS["r"]))
```

C) Pydobot 라이브러리: PTP 커멘트

```
dobot.move_to(tx, ty, tz, tr)
```

D) Dobot 펌웨어 : Analytic IK 풀이

- 4-DOF Manipulator → θ_1, θ_2, θ_3 ,θ_4 해석적 계산

INDEX

01 팀 소개 및 진행 일정

02 프로젝트 시나리오

03 추진 배경 및 필요성

04 시스템 구현 및 핵심 기술

05 트러블슈팅 및 성능 평가

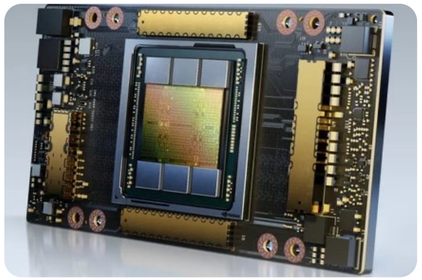
06 아쉬운 점 및 향후 발전 방향

05 / TROUBLESHOOTING PIPELINE

AI 로봇 시스템 전체 파이프라인과 핵심 오류 매핑

프로젝트 과정 중 발생한 오류를 해결

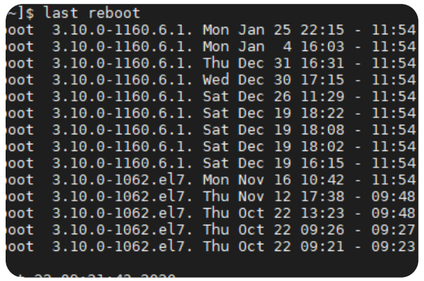
01



데이터 서버로 보낼 시 파일 누락

데이터 전송 시 scp 명령어 뒤에 –r
파일 전체 복사 옵션이 붙도록

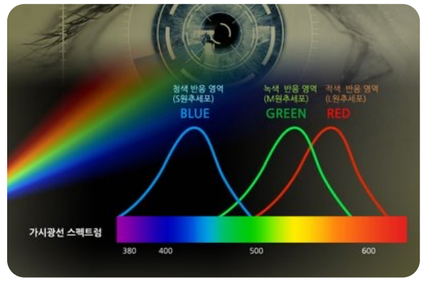
02



Pi0 – FAST garbage 토큰 출력

Pi0 모델 적용
토큰 포맷 문제 해결

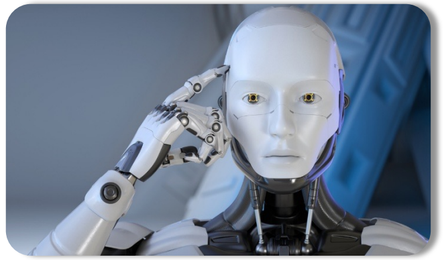
03



학습 때 밝기/색감 변화시 추론 성능 저하

모든 스크립트 카메라 수동 설정 적용

04



DOBOT 특이점 충돌

DH 파라미터 기반 올바른 공식으로 교체
& 우회점 생성

05 / TROUBLESHOOTING PIPELINE

트러블슈팅 정량 성과: Before → After

4건 전원 해결 → 데이터 수집·학습·추론 전 구간 파이프라인 안정화 완료

트러블 항목	Before (해결 전)	After (해결 후)	개선폭
카메라 노출/WB 불일치	에피소드마다 밝기·색감 변동 → 추론 성능 저하	수동 노출/WB 고정 → 일관된 이미지 품질	편차 제거
scp 파일 누락	이미지 파일 전송률 0% (폴더 구조만 복사)	-r 플래그 추가 → 전체 파일 정상 전송	0% → 100%
Pi0-FAST garbage 토큰	유효 Action 출력 0% (의미 없는 토큰 시퀀스)	Pi0(flow-matching) 전환 → 토큰 포맷 문제 해소	오류 완전 해소
Singularity 경계 오류	ALARM 빈발 (경계 오차 59mm) → 작업 중단 반복	DH 파라미터 기반 공식 → 정확한 경계 설정	오차 0mm

INDEX

01 팀 소개 및 진행 일정

02 프로젝트 시나리오

03 추진 배경 및 필요성

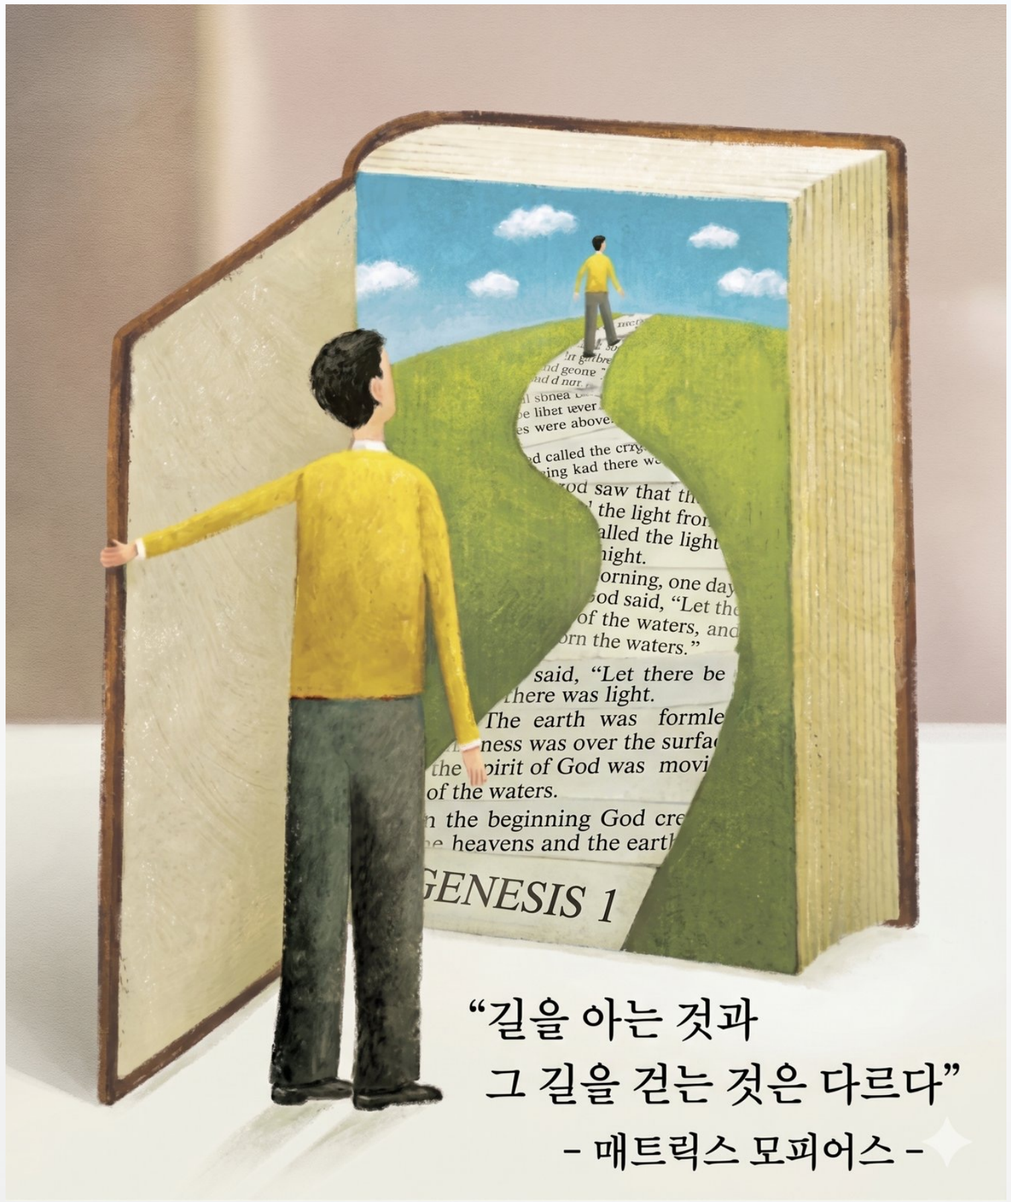
04 시스템 구현 및 핵심 기술

05 트러블슈팅 및 성능 평가

06 아쉬운 점 및 향후 발전 방향

INNOVATING YOUR FUTURE

06 / Limitations & Future Work



06 / Limitations & Future Work

하드웨어의 물리적 한계

4축 자유도 부족

6-DOF는 과자를 입에 넣어주는 동작이 가능하지만, 4-DOF는 지정 영역에 놓는 것만 가능

그리퍼의 한계

크기가 작아 큰 물체를 잡지 못하고, 집게 형태라 둥글거나 미끄러운 물체 파지가 어려움

리스트 카메라

카메라과 그리퍼의 시선 방향 불일치로 좌표 오차가 누적됨

What If?

만약 4축 대신 6축 로봇을 사용했다면 어땠을까?

만약 집게형 그리퍼 대신 '진공 흡착 툴'을 썼다면 어땠을까?

만약 다각도에 카메라를 '더' 설치했다면 어땠을까?





데이터셋 구축의 한계와 대안

병목: 12일의 시간 제약

- $\pi 0$ 요구량

에피소드당 50~150프레임 연속 궤적

- 실제 수집량

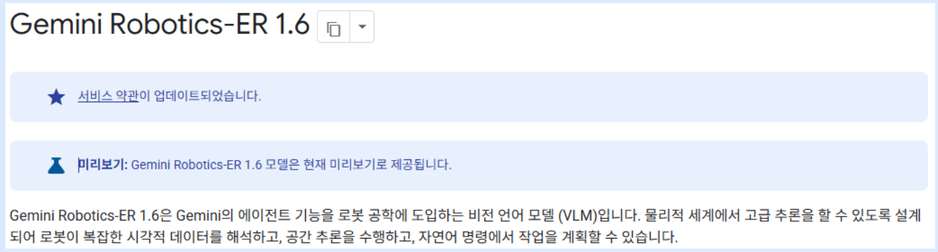
웨이포인트 방식 → 에피소드당 10~20스텝

필요 에피소드: 50~100개

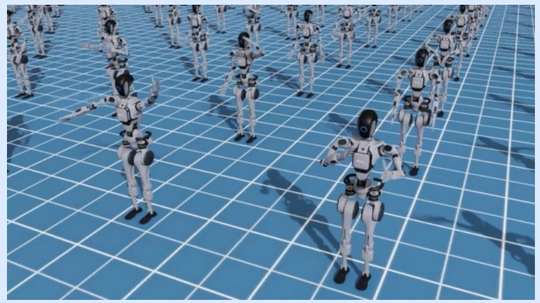
학습 1 사이클 = 수 시간 소요

대안적 접근

- Gemini API 하이브리드 구조



- NVIDIA Isaac Sim 디지털 트윈





06 / Limitations & Future Work

다양한 모델을 비교하지 못한 한계와 아쉬움

$\pi 0$-FAST (~3B)

FAST 토크나이저로 액션을
이산 토큰으로 변환하여 생성

결과: 동작이 제대로 생성되지 않음

이산 토큰 방식이 우리 태스크의
연속적인 로봇 제어에 부적합

$\pi 0$ (3.3B)

Flow Matching으로
연속적인 액션을 직접 생성

결과: 동작 품질 개선

연속 제어에 적합한 flow matching이
안정적이고 예측 가능한 행동 생성

아쉬운 점: OpenVLA(7B) 등 더 큰 모델을 사용했다면 시각적 이해력과 동작 생성 품질 모두 개선 가능성이 있었으나, GPU 메모리 (VRAM) 제약으로 시도하지 못함

향후 발전 방향



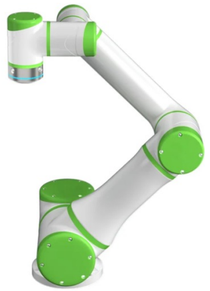
제 3의 손

책상 위 고정 공간에서만 동작 가능
4-DOF 제약으로 단순 파지만 수행
서비스 범위가 매우 제한적



이동형 로봇 비서

자율주행 로봇과 로봇 팔을 결합하여, 책상을 벗어나 집 안 전체 공간에서 사용자에게 능동적으로 서비스를 제공



자유로운 동작이 가능한 6-DOF 로봇

6축 협동로봇에 VLA 모델을 적용하면, 과자를 집어 사용자의 입에 넣어주는 것처럼 다양한 각도와 궤적의 섬세한 동작이 가능

THANK YOU

감사합니다